

FOREIGN TRADE UNIVERSITY

FDC104



FINAL REPORT

PHÂN TÍCH HÀNH VI, DỰ ĐOÁN KHÁCH HÀNG SỬ DỤNG DỊCH VỤ TIỀN GỬI TIỀN KỲ HẠN

***“CHALLENGE 2: MACHINE LEARNING - UNDERSTANDING CUSTOMER BEHAVIOR
WITH DEPOSIT PRODUCTS FROM BANK X MARKETING DATA SET”***

Subject : Phân tích dữ liệu nâng cao trong Kinh tế và Kinh doanh

Code : FDC105

Group number : Group 09

Lecturer : Mr Nguyen Tien Huy

Hanoi – June, 2025

FOREIGN TRADE UNIVERSITY

FDC104



FINAL REPORT

PHÂN TÍCH HÀNH VI, DỰ ĐOÁN KHÁCH HÀNG SỬ DỤNG DỊCH VỤ TIỀN GỬI TIỀN KỲ HẠN

***“CHALLENGE 2: MACHINE LEARNING - UNDERSTANDING CUSTOMER BEHAVIOR
WITH DEPOSIT PRODUCTS FROM BANK X MARKETING DATA SET”***

Subject : Phân tích dữ liệu nâng cao trong Kinh tế và Kinh doanh

Code : FDC105

Group number : Group 09

Lecturer : Mr Nguyen Tien Huy

Hanoi – June, 2025

TABLE OF CONTRIBUTION

No.	Student name	Student ID	Contribution
1	Nguyễn Minh Sơn		
2	Trần Khôi Nguyên		
3	Bý Quốc Đạt		
4	Trịnh Như Phương		
5	Tạ Đường Phương Thảo		
6	Lê Thùy Linh		

MỤC LỤC

LỜI MỞ ĐẦU.....	1
PHẦN 1: MỤC TIÊU, CƠ SỞ LÝ THUYẾT VÀ PHẠM VI NGHIÊN CỨU.....	2
1.1. Mục tiêu nghiên cứu.....	2
1.2. Cơ sở lý thuyết.....	3
1.2.1. Nghiên cứu về marketing ngân hàng và hành vi khách hàng.....	3
1.2.2. Nghiên cứu về ứng dụng của học máy (Machine Learning).....	4
1.3. Phương pháp và đối tượng nghiên cứu	4
1.3.1. Mô hình Machine Learning được sử dụng trong nghiên cứu	4
1.3.2. Đối tượng phân tích và nghiên cứu của dự án.....	5
1.4. Phạm vi nghiên cứu.....	5
1.4.1. Phạm vi thời gian.....	5
1.4.2. Phạm vi địa lý	5
1.4.3. Phạm vi nội dung	6
1.4.4. Phạm vi kỹ thuật.....	6
PHẦN 2: TRIỂN KHAI NGHIÊN CỨU	7
2.1. Phân tích dữ liệu khám phá - Exploratory Data Analysis	7
2.1.1. Phân tích dữ liệu nhân khẩu học	7
2.1.2. Phân tích hành vi khách hàng.....	9
2.1.3. Phân tích hiệu quả chiến dịch.....	12
2.2. Xây dựng mô hình dự đoán khách hàng gửi tiền tiết kiệm	15

2.2.1.	<i>Xác định các biến đưa vào mô hình.....</i>	15
2.2.2.	<i>Tiền xử lý dữ liệu</i>	15
2.2.3.	<i>Xây dựng mô hình</i>	16
2.3.	<i>Kết quả.....</i>	18
2.3.1.	<i>Phân tích kết quả mô hình</i>	20
2.3.2.	<i>Dự đoán khách hàng gửi tiền tiết kiệm</i>	20
PHẦN 3:	<i>GIẢI PHÁP VÀ KIẾN NGHỊ.....</i>	22
3.1.	<i>Ứng dụng của mô hình dự đoán</i>	22
3.2.	<i>Các giải pháp và đề xuất về mặt nghiệp vụ.....</i>	22
3.3.	<i>Kiến nghị về mô hình dữ liệu và thu thập dữ liệu.....</i>	23
THAM KHẢO.....		25

LỜI MỞ ĐẦU

Nghiên cứu của nhóm 9 tập trung vào việc phân tích hành vi sử dụng dịch vụ tiền gửi tiết kiệm của khách hàng tại một ngân hàng thương mại tại Bồ Đào Nha, dựa trên bộ dữ liệu thực tế từ cuộc thi “Challenge 2: Machine Learning – Understanding Customer Behavior with Deposit Products from Bank X Marketing Dataset”. Mục tiêu chính của dự án là tìm hiểu các yếu tố ảnh hưởng đến quyết định sử dụng hoặc từ bỏ dịch vụ gửi tiền kỳ hạn trên nền tảng ngân hàng số, từ đó xây dựng mô hình phân loại và phân cụm khách hàng nhằm dự đoán xu hướng hành vi trong tương lai.

Nhóm đã nghiên cứu áp dụng phương pháp phân tích định lượng với các mô hình học máy có giám sát nhằm dự đoán hành vi đăng ký tiền gửi tiết kiệm của khách hàng (biến mục tiêu: y – yes/no). XGBoost và Random Forest là hai mô hình chính, bên cạnh Logistic Regression và Decision Tree được dùng để thiết lập baseline. Dữ liệu đầu vào được xử lý qua One-Hot Encoding, chuẩn hóa và tích hợp vào Pipeline. Hiệu suất mô hình được đánh giá bằng các chỉ số độ chính xác, ma trận nhầm lẫn và báo cáo phân loại, hỗ trợ đề xuất chiến lược tiếp cận khách hàng hiệu quả hơn.

NỘI DUNG

PHẦN 1: MỤC TIÊU, CƠ SỞ LÝ THUYẾT VÀ PHẠM VI NGHIÊN CỨU

1.1. Mục tiêu nghiên cứu

Trong bối cảnh cạnh tranh ngày càng gay gắt giữa các tổ chức tài chính, hoạt động marketing ngày càng đóng vai trò quan trọng trong việc thu hút và giữ chân khách hàng. Việc tận dụng dữ liệu lịch sử để phân tích và dự đoán hành vi khách hàng không chỉ giúp ngân hàng tối ưu hóa chiến dịch tiếp thị mà còn nâng cao hiệu quả sử dụng nguồn lực và cải thiện tỷ lệ chuyển đổi.

Bộ dữ liệu Bank Marketing từ UCI Machine Learning Repository chứa thông tin chi tiết về các chiến dịch tiếp thị qua điện thoại được một ngân hàng Bồ Đào Nha thực hiện nhằm thuyết phục khách hàng đăng ký sản phẩm tiền gửi có kỳ hạn. Dữ liệu bao gồm cả yếu tố nhân khẩu học, lịch sử tương tác với khách hàng, và các chỉ số kinh tế vĩ mô tại thời điểm diễn ra chiến dịch.

Trên cơ sở đó, nghiên cứu này được thực hiện với các mục tiêu cụ thể sau:

1. Xác định các yếu tố ảnh hưởng chính đến quyết định đăng ký tiền gửi của khách hàng.

Thông qua phân tích thống kê và mô hình học máy, nghiên cứu sẽ đánh giá mức độ ảnh hưởng của các biến đầu vào (tuổi, nghề nghiệp, số lần liên hệ, thời gian gọi điện, v.v.) đến khả năng khách hàng đồng ý tham gia sản phẩm gửi tiết kiệm.

2. Xây dựng và so sánh các mô hình dự đoán hành vi khách hàng.

Nghiên cứu sẽ áp dụng các thuật toán học máy như Logistic Regression, Decision Tree, Random Forest, và XGBoost để dự đoán xác suất khách hàng sẽ đăng ký tiền gửi. Các mô hình sẽ được đánh giá dựa trên độ chính xác, khả năng phân biệt (AUC), và tính ổn định.

3. Đề xuất giải pháp tối ưu hóa chiến dịch marketing dựa trên kết quả phân tích.

Dựa vào các phát hiện từ mô hình, nghiên cứu sẽ đưa ra kiến nghị thực tiễn giúp ngân hàng xác định đối tượng khách hàng tiềm năng và xây dựng chiến dịch tiếp thị hiệu quả hơn trong tương lai.

Thông qua việc kết hợp giữa phân tích dữ liệu và kỹ thuật học máy, nghiên cứu kỳ vọng sẽ đóng góp một góc nhìn thực tiễn và khoa học vào lĩnh vực marketing ngân hàng hiện đại.

1.2. Cơ sở lý thuyết

Trong những năm gần đây, việc ứng dụng khoa học dữ liệu và trí tuệ nhân tạo vào lĩnh vực ngân hàng ngày càng trở nên phổ biến, đặc biệt là trong hoạt động marketing và chăm sóc khách hàng. Các nghiên cứu cho thấy rằng việc khai thác dữ liệu khách hàng một cách hiệu quả có thể giúp ngân hàng không chỉ tiết kiệm chi phí tiếp thị mà còn nâng cao tỷ lệ chuyển đổi và mức độ hài lòng của khách hàng.

1.2.1. Nghiên cứu về marketing ngân hàng và hành vi khách hàng

Theo VinUni (2024), marketing ngân hàng là quá trình tổng hợp các hoạt động từ nghiên cứu thị trường, xây dựng sản phẩm, định vị thương hiệu, đến phát triển các chiến lược truyền thông nhằm hướng đến đúng đối tượng khách hàng và tối ưu hóa hiệu quả kinh doanh. Trong bối cảnh số hóa mạnh mẽ, hành vi khách hàng ngày càng phức tạp, việc dự đoán xu hướng hành động của họ trở thành yếu tố cốt lõi trong chiến lược marketing hiện đại.

Một số nghiên cứu trong và ngoài nước đã tập trung vào việc phân tích dữ liệu hành vi khách hàng trong ngành ngân hàng. Richards & Laughlin (1980) nhấn mạnh vai trò của thông tin khách hàng trong việc xây dựng chiến lược tài chính hiệu quả. Lazaridis &

Tryfonidis (2006) chứng minh mối quan hệ giữa các yếu tố tài chính và hiệu suất hoạt động, khẳng định tầm quan trọng của phân tích dữ liệu định lượng trong ra quyết định.

1.2.2. Nghiên cứu về ứng dụng của học máy (Machine Learning)

Bộ dữ liệu Bank Marketing từ UCI là một tập dữ liệu nổi tiếng được sử dụng rộng rãi trong các nghiên cứu về dự đoán hành vi khách hàng trong lĩnh vực ngân hàng. Moro, Laureano & Cortez (2014) là một trong những nhóm nghiên cứu đầu tiên phân tích sâu bộ dữ liệu này, sử dụng các thuật toán như Decision Tree, Random Forest và Neural Networks để dự đoán khả năng khách hàng đăng ký gửi tiền có kỳ hạn. Kết quả chỉ ra rằng các mô hình học máy phi tuyến tính như Random Forest và Neural Networks cho hiệu quả dự đoán tốt hơn các mô hình tuyến tính truyền thống. Nghiên cứu của Sahu et al. (2021) cũng sử dụng bộ dữ liệu Bank Marketing và so sánh hiệu quả giữa các thuật toán Logistic Regression, Support Vector Machine, và XGBoost. Kết quả cho thấy XGBoost có độ chính xác cao nhất, đồng thời khả năng diễn giải mô hình cũng được cải thiện nhờ kỹ thuật phân tích độ quan trọng của biến (feature importance).

1.3. Phương pháp và đối tượng nghiên cứu

1.3.1. Mô hình Machine Learning được sử dụng trong nghiên cứu

Phân tích định lượng là phương pháp chính trong nghiên cứu này, sử dụng các mô hình học máy (Machine Learning) nhằm dự đoán khả năng khách hàng đăng ký sản phẩm tiền gửi có kỳ hạn (biến mục tiêu y). Dữ liệu được xử lý bằng các kỹ thuật mã hóa, chuẩn hóa và trực quan hóa, từ đó huấn luyện và đánh giá các mô hình dự đoán. Các mô hình chính bao gồm:

- **XGBoost Classifier (xgboost.XGBClassifier)**
Mô hình tăng cường cây quyết định được tối ưu hóa về hiệu suất và tốc độ. XGBoost phù hợp với dữ liệu có nhiều biến phân loại và tương tác phi tuyến. Mô hình này xử lý tốt các đặc trưng như job, education, duration, housing, loan, default và cho kết quả AUC cao.
- **Random Forest (sklearn.ensemble.RandomForestClassifier)**
Một mô hình học máy ensemble giúp tránh overfitting và cho kết quả ổn định. Được sử dụng như mô hình so sánh (benchmark) để đánh giá hiệu quả dự đoán so với XGBoost.
- **Logistic Regression & Decision Tree Classifier**
Hai mô hình tuyến tính và phân loại cơ bản được sử dụng làm baseline. Logistic Regression giúp kiểm tra ảnh hưởng tuyến tính giữa biến độc lập và biến mục tiêu. Decision Tree cho phép phân tích logic phân nhánh và mức độ quan trọng của từng đặc trưng.

- **Trực quan hóa và đánh giá mô hình**

Các thư viện Python như seaborn, matplotlib, plotly được dùng để trực quan hóa phân phối dữ liệu, biểu đồ tương quan và dữ liệu thiếu (missingno). Đánh giá mô hình dựa trên các chỉ số như: accuracy_score, precision, recall, F1-score, AUC-ROC, và confusion_matrix từ sklearn.metrics.

1.3.2. Đối tượng phân tích và nghiên cứu của dự án

Dự án tập trung phân tích hành vi khách hàng cá nhân của một ngân hàng tại châu Âu, trong chiến dịch tiếp thị qua điện thoại nhằm quảng bá sản phẩm tiền gửi có kỳ hạn. Dữ liệu thể hiện mối quan hệ giữa đặc điểm cá nhân, lịch sử tương tác và quyết định gửi tiền.

- **Đặc điểm nhân khẩu học**

- age: Tuổi khách hàng (liên tục)
- job: Nghề nghiệp (quản lý, kỹ thuật, sinh viên, hưu trí,...)
- marital: Tình trạng hôn nhân (độc thân, kết hôn, ly dị)
- education: Trình độ học vấn (tiểu học, trung học, đại học,...)

- **Tình trạng tài chính**

- balance: Số dư trung bình tài khoản (EUR)
- housing: Đang vay mua nhà (yes/no)
- loan: Đang vay tiêu dùng cá nhân (yes/no)
- default: Có đang trong tình trạng nợ xấu không

- **Hành vi tương tác marketing**

- contact: Hình thức liên hệ (di động / điện thoại bàn)
- month, day: Thời điểm khách hàng được liên hệ
- duration: Thời lượng cuộc gọi
- campaign: Số lần liên hệ trong chiến dịch hiện tại
- previous, pdays: Lịch sử tương tác trong chiến dịch trước
- poutcome: Kết quả chiến dịch tiếp thị trước (success, failure,...)

- **Biến mục tiêu**

- y: Kết quả tiếp thị (yes: đồng ý đăng ký / no: từ chối)

1.4. Phạm vi nghiên cứu

1.4.1. Phạm vi thời gian

Dữ liệu không cung cấp năm cụ thể, nhưng thể hiện thời gian tiếp cận khách hàng qua các biến day, month, pdays.

Cho phép đánh giá hiệu quả tiếp thị theo mùa vụ và tần suất liên hệ.

1.4.2. Phạm vi địa lý

Dữ liệu được thu thập từ khách hàng của một ngân hàng tại Bồ Đào Nha, đại diện cho khu vực Tây Âu.

Có thể được mở rộng để áp dụng vào các hệ thống ngân hàng bán lẻ tại châu Âu có mô hình tương tự.

1.4.3. Phạm vi nội dung

Tập trung vào hành vi khách hàng đối với sản phẩm tiền gửi có kỳ hạn sau tiếp thị qua điện thoại.

Đánh giá mối liên hệ giữa yếu tố nhân khẩu học, tài chính và tương tác marketing đến quyết định hành vi.

1.4.4. Phạm vi kỹ thuật

Xử lý dữ liệu: Mã hóa One-Hot/Label Encoding, xử lý mất cân bằng với SMOTE (nếu cần), chuẩn hóa với StandardScaler.

Huấn luyện mô hình: Logistic Regression, Decision Tree, Random Forest, XGBoost.

Đánh giá: Dùng confusion matrix, AUC-ROC, F1-score, accuracy.

Trực quan hóa: Bar chart, heatmap, ROC curve, biểu đồ cây phân loại.

PHẦN 2: TRIỂN KHAI NGHIÊN CỨU

2.1. Phân tích dữ liệu khám phá - Exploratory Data Analysis


2.1.1. Phân tích dữ liệu nhân khẩu học

a. Độ tuổi

Các khách hàng tập trung chủ yếu ở 3 nhóm tuổi:

- Từ 30-34: 9,740 khách hàng
- Từ 35-39: 8,349 khách hàng
- Từ 40-44: 6,185 khách hàng


Trong đó, độ tuổi trung bình là 41 tuổi.



b. Nghề nghiệp


Nghề nghiệp khách hàng được chia làm 12 nhóm, bao gồm cả nhóm thất nghiệp và không xác định nghề nghiệp,

Đáng chú ý, trong phân loại nghề nghiệp, có 4 nhóm khách hàng có từ 5,000 người trở lên, theo thứ tự lần lượt là: Lao động chân tay, Quản lý, Kỹ thuật và Chuyên viên.



c. Tình trạng quan hệ


Có 27,214 khách hàng Đã kết hôn, chiếm tới hơn 50% trong bộ dữ liệu. Tiếp theo là gần 13 nghìn khách hàng Độc thân, xếp cuối cùng là hơn 5 nghìn khách hàng Đã ly hôn.



d. Trình độ học vấn


Về trình độ học vấn, phần lớn khách hàng (~80%) có trình độ Phổ thông (23,202) hoặc Đại học (13,301). Chỉ có khoảng 7 nghìn khách hàng học hết Mầm non, và chưa tới 2 nghìn khách hàng

không xác định được trình độ. Nhìn chung, tập khách hàng của Ngân hàng X hầu hết có học thức và hiểu biết xã hội.




e. Tương quan giữa các dữ liệu nhân khẩu học

Khách hàng trong nhóm tuổi chiếm đa số phần lớn đều là đã kết hôn.



2.1.2. Phân tích hành vi khách hàng


a. Số dư tài khoản theo nghề nghiệp





- Không có sự khác biệt đặc biệt lớn giữa về số dư tài khoản giữa các nghề nghiệp khác nhau, chủ yếu trong khoảng từ 1,000 đến 2,000.
- Nhóm Nghỉ hưu có số dư tài khoản lớn nhất, trong khi nhóm Dịch vụ có số dư tài khoản thấp nhất.

b. Khoản vay

- Có 44% khách hàng vay mua nhà và 16% khách hàng vay cá nhân.
- Tỷ lệ vỡ nợ chỉ chiếm dưới 2%.
- Khách vay mua nhà chủ yếu trong độ tuổi từ 30-44.
- Khách vay cá nhân có tỷ lệ thấp, trải dài từ 30-60 tuổi, không có độ tuổi nào vay cá nhân tăng đột biến.






→ Nhu cầu vay mua nhà khá cao và khách hàng vay mua nhà tập trung chủ yếu ở nhóm tuổi chiếm đa số trong bộ dữ liệu và tình trạng quan hệ là đã kết hôn.


b. Tiền gửi tiết kiệm

- Khách hàng có tiền gửi tiết kiệm không cao đột biến ở độ tuổi nào trong tập dữ liệu, tuy nhiên có thể nhận thấy tập khách hàng chiếm đa số (độ tuổi từ 30-44) tuy là nhóm có tỉ lệ vay mua nhà cao lại có tỉ lệ gửi tiết kiệm thấp nhất so với các nhóm còn lại.
- Nghề nghiệp cũng ảnh hưởng đến hành vi gửi tiền. Những khách hàng là người đã nghỉ hưu, sinh viên và nội trợ có tỷ lệ đăng ký tiền gửi kỳ hạn cao hơn so với các nhóm khác. Điều này có thể do người nghỉ hưu có xu hướng tiết kiệm và đầu tư an toàn, còn sinh viên có thể đăng ký theo chương trình ưu đãi cho HSSV khi gửi tiết kiệm hoặc đây là các tài khoản được phụ huynh quản lý và gửi tiền tiết kiệm cho con về sau.






2.1.3. Phân tích hiệu quả chiến dịch



- Phần lớn khách hàng được liên hệ trong các tháng 5, 6, 7 và 8 của năm trước. Trong đó, tháng 5 là tháng có số lượng khách hàng được liên hệ nhiều nhất nhưng lại có tỷ lệ đăng ký tiền gửi kỳ hạn thấp nhất. Ngược lại, các tháng 3, 9 và 12 có rất ít khách hàng được liên hệ, tuy nhiên đây lại là những tháng nên được ngân hàng tập trung tiếp cận nhiều hơn trong các chiến dịch sau.




- Nếu khách hàng từng tham gia chiến dịch trước nhưng kết quả là “thất bại”, thì khả năng họ tiếp tục từ chối trong chiến dịch hiện tại là khoảng 87.5%. Cụ thể, trong số những người từng có kết quả thất bại trước đó, chỉ 12.6% tiếp tục đăng ký tiền gửi, còn lại không đăng ký.
- Ngược lại, nếu chiến dịch trước đó được đánh giá là “thành công”, thì tỷ lệ khách hàng tiếp tục đăng ký tiền gửi kỳ hạn lên tới 64.3%, cho thấy sự ảnh hưởng tích cực rất lớn từ trải nghiệm thành công trước đó.



- Thời lượng cuộc gọi cũng ảnh hưởng đến tỉ lệ gửi tiền của khách hàng. Thời lượng cuộc gọi càng dài, khách hàng càng có xu hướng gửi tiền tiết kiệm cao hơn, cho thấy việc trao đổi cụ thể, chi tiết và rõ ràng đến khách hàng đúng nhu cầu sẽ có thể khuyến khích khách hàng sử dụng sản phẩm cao hơn.



- Việc liên hệ khách hàng quá nhiều lần qua các chiến dịch khác nhau có thể gây phản tác dụng. Nếu một khách hàng bị liên hệ quá nhiều lần, khả năng họ từ chối đăng ký tiền gửi kỳ hạn sẽ cao hơn. Do đó, ngân hàng nên giới hạn số lần liên hệ ở một mức hợp lý hoặc là có biện pháp ghi chú lại xem đã liên lạc bao nhiêu lần.



II.2.4. Nhận định về bộ dữ liệu sau khi phân tích

- Nhóm tuổi trung niên tuy có số lượng đăng ký nhiều, nhưng cũng là nhóm có tỷ lệ từ chối cao nhất. Trong khi đó, nhóm khách hàng lớn tuổi có xu hướng đăng ký tiền gửi kỳ hạn

cao hơn và tỷ lệ từ chối thấp hơn. Vì vậy, ngân hàng nên tập trung vào nhóm khách hàng cao tuổi để tối ưu hóa tỷ lệ chuyển đổi.

- Những khách hàng không vay mua nhà (housing loan = no) lại có xu hướng quan tâm đến tiền gửi kỳ hạn hơn. Đồng thời, khách hàng có số dư tài khoản cao hơn mức trung bình cũng có khả năng đăng ký tiền gửi cao hơn.

2.2. Xây dựng mô hình dự đoán khách hàng gửi tiền tiết kiệm

2.2.1. Xác định các biến đưa vào mô hình

a. Các biến số dùng để phân nhóm:

- age (numeric): Tuổi khách hàng
- balance: số dư trung bình năm của tài khoản
- day: ngày liên hệ gần nhất trong tháng
- month: tháng liên hệ gần nhất trong năm
- duration: thời lượng liên hệ
- campaign: số lần liên hệ đã thực hiện trong chiến dịch đối, bao gồm lần gần nhất
- pdays: số ngày sau khi khách hàng được liên hệ gần nhất từ chiến dịch trước
- previous: số lượng liên hệ đã thực hiện trước chiến dịch đối với khách hàng
- outcome: kết quả của chiến dịch trước

b. Các biến phân loại khác

- job : Nghề nghiệp khách hàng
- marital : tình trạng quan hệ
- education: trình độ học vấn
- default: có nợ xấu hay không
- contact: hình thức liên hệ khách hàng
- housing: khách hàng có vay mua nhà hay không?
- loan: khách hàng có vay mua cá nhân hay không?

c. Biến mục tiêu

- target: khách hàng có gửi tiền tiết kiệm hay không? (binary: "yes", "no")

2.2.2. Tiền xử lý dữ liệu

a. Xử lý các biến

```

cat_features = df.select_dtypes(include=['object', 'bool']).columns.values
print(cat_features)

['job' 'marital' 'education' 'default' 'housing' 'loan' 'contact' 'month'
 'poutcome' 'y']

df_encoded = pd.get_dummies(df, columns=['job', 'marital', 'education', 'default', 'housing', 'loan', 'contact', 'month', 'poutcome'])

# Initialize the LabelEncoder
label_encoder = LabelEncoder()

# Fit and transform the 'y' column to numerical values
df_encoded['y'] = label_encoder.fit_transform(df_encoded['y'])

# Train-Test split
X = df_encoded.drop(columns=['y'])
y = df_encoded['y']

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=36)

```

```

# Calculate the count of 'yes' and 'no' in the 'y' column
yes_count = (df['y'] == 'yes').sum()
no_count = (df['y'] == 'no').sum()

# Calculate the total count of values in the 'y' column
total_count = len(df)

# Calculate the percentage of 'yes' and 'no'
percentage_yes = (yes_count / total_count) * 100
percentage_no = (no_count / total_count) * 100
print("before sampling")
print("Percentage of 'yes' in 'y':", percentage_yes)
print("Percentage of 'no' in 'y':", percentage_no)

```

```

before sampling
Percentage of 'yes' in 'y': 11.698480458295547
Percentage of 'no' in 'y': 88.30151954170445

```

```

scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

```

```

X_train_scaled = pd.DataFrame(X_train_scaled, columns=X_train.columns)
X_test_scaled = pd.DataFrame(X_test_scaled, columns=X_test.columns)

```

```

from imblearn.over_sampling import SMOTE

smote = SMOTE(random_state=36)
X_resampled, y_resampled = smote.fit_resample(X_train_scaled, y_train)

```

2.2.3. Xây dựng mô hình

4.3.1. Logistic Regression

```
log_reg = LogisticRegression(class_weight='balanced')
log_reg.fit(X_resampled, y_resampled)
```

LogisticRegression(class_weight='balanced')

In a Jupyter environment, please rerun this cell to show the HTML representation or trust the notebook.

On GitHub, the HTML representation is unable to render, please try loading this page with nbviewer.org.



LogisticRegression

[?Documentation for LogisticRegressionFitted](#)

LogisticRegression(class_weight='balanced')

```
# Make predictions on the test set
y_pred = log_reg.predict(X_test_scaled)

# Calculate accuracy
accuracy = metrics.accuracy_score(y_test, y_pred)
print("Accuracy:", accuracy)

# Generate a classification report for the test set
print("\nClassification Report for Test Set:")
print(classification_report(y_test, y_pred))

# Generate a confusion matrix for the test set
print("\nConfusion Matrix for Test Set:")
print(confusion_matrix(y_test, y_pred))
plt.figure(figsize=(8, 6))
sns.heatmap(confusion_matrix(y_test, y_pred), annot=True, cmap='Blues', fmt='g')
plt.xlabel('Predicted')
plt.ylabel('Actual')
plt.title('Confusion Matrix')
plt.show()
```

4.3.2. Random Forest Classifier

```
random_forest = RandomForestClassifier(n_estimators=100, random_state=36)
```

```
# Train the model
random_forest.fit(X_resampled, y_resampled)
```

RandomForestClassifier(random_state=36)

In a Jupyter environment, please rerun this cell to show the HTML representation or trust the notebook.

On GitHub, the HTML representation is unable to render, please try loading this page with nbviewer.org.



RandomForestClassifier

[?Documentation for RandomForestClassifierFitted](#)

RandomForestClassifier(random_state=36)

```
y_pred = random_forest.predict(X_test_scaled)
```

```
test_accuracy = accuracy_score(y_test, y_pred)
print("\nTest Accuracy:", test_accuracy)

# Generate a classification report for the test set
print("\nClassification Report for Test Set:")
print(classification_report(y_test, y_pred))

# Generate a confusion matrix for the test set
print("\nConfusion Matrix for Test Set:")
print(confusion_matrix(y_test, y_pred))
plt.figure(figsize=(8, 6))
sns.heatmap(confusion_matrix(y_test, y_pred), annot=True, cmap='Blues', fmt='g')
plt.xlabel('Predicted')
plt.ylabel('Actual')
plt.title('Confusion Matrix')
plt.show()
```

4.3.3. Decision Tree

```
### *4.3.2. Random Forest Classifier*
decision_tree = DecisionTreeClassifier(random_state=36)

decision_tree.fit(X_resampled, y_resampled)
```

DecisionTreeClassifier(random_state=36)

In a Jupyter environment, please rerun this cell to show the HTML representation or trust the notebook.

On GitHub, the HTML representation is unable to render, please try loading this page with nbviewer.org.



DecisionTreeClassifier

?Documentation for DecisionTreeClassifierFitted

DecisionTreeClassifier(random_state=36)

```
# Make predictions on the test data
y_test_pred = decision_tree.predict(X_test_scaled)

# Calculate and print accuracy for the test set
test_accuracy = accuracy_score(y_test, y_test_pred)
print("\nTest Accuracy:", test_accuracy)

# Generate a classification report for the test set
print("\nClassification Report for Test Set:")
print(classification_report(y_test, y_test_pred))

# Generate a confusion matrix for the test set
print("\nConfusion Matrix for Test Set:")
print(confusion_matrix(y_test, y_test_pred))

plt.figure(figsize=(8, 6))
sns.heatmap(confusion_matrix(y_test, y_test_pred), annot=True, cmap='Blues', fmt='g')
plt.xlabel('Predicted')
plt.ylabel('Actual')
plt.title('Confusion Matrix')
plt.show()
```

4.3.4. XGBoost Classifier

```
xg_boost = xgb.XGBClassifier(objective='binary:logistic', random_state=42)
```

```
# Train the model on the training data
xg_boost.fit(X_resampled, y_resampled)
```

<style>#sk-container-id-18 { ●●●

```
# Make predictions on the test data
y_test_pred = xg_boost.predict(X_test_scaled)


# Calculate and print accuracy for the test set
test_accuracy = accuracy_score(y_test, y_test_pred)
print("\nTest Accuracy:", test_accuracy)

# Generate a classification report for the test set
print("\nClassification Report for Test Set:")
print(classification_report(y_test, y_test_pred))

# Generate a confusion matrix for the test set
print("\nConfusion Matrix for Test Set:")
print(confusion_matrix(y_test, y_test_pred))

plt.figure(figsize=(8, 6))
sns.heatmap(confusion_matrix(y_test, y_test_pred), annot=True, cmap='Blues', fmt='g')
plt.xlabel('Predicted')
plt.ylabel('Actual')
plt.title('Confusion Matrix')
plt.show()
```

2.3.Kết quả




Test Accuracy: 0.9051902093777646

Classification Report for Test Set:

| | precision | recall | f1-score | support |
|--------------|-----------|--------|----------|---------|
| 0 | 0.94 | 0.95 | 0.95 | 11944 |
| 1 | 0.61 | 0.57 | 0.59 | 1620 |
| accuracy | | | 0.91 | 13564 |
| macro avg | 0.78 | 0.76 | 0.77 | 13564 |
| weighted avg | 0.90 | 0.91 | 0.90 | 13564 |

Confusion Matrix for Test Set:

```
[[11350  594]
 [ 692  928]]
```



2.3.1. Phân tích kết quả mô hình

a. Lựa chọn mô hình

Sau khi thử nghiệm nhiều mô hình như Logistic Regression, Decision Tree, Random Forest và XGBoost, nhóm quyết định lựa chọn XGBoost Classifier là mô hình chính cho bài toán dự đoán hành vi gửi tiền tiết kiệm.

Lý do:

AUC đạt 0.93, cao nhất trong số các mô hình thử nghiệm → khả năng phân biệt giữa hai lớp (đồng ý vs từ chối) là rất tốt.

Khả năng xử lý dữ liệu phân loại hiệu quả, mô hình hóa được các tương tác phi tuyến tính và kiểm soát overfitting tốt hơn Decision Tree.

2.3.2. Dự đoán khách hàng gửi tiền tiết kiệm

Biến mục tiêu y gồm hai giá trị: yes (đăng ký gửi tiền) và no (không đăng ký). Kết quả phân loại của mô hình XGBoost:

- Độ chính xác tổng thể (Accuracy): 90.5%
- Precision class 1 (yes): 0.61 → Khi mô hình dự đoán khách hàng sẽ gửi tiền, đúng khoảng 61% trường hợp.
- Recall class 1 (yes): 0.57 → Mô hình phát hiện đúng 57% số khách hàng thật sự gửi tiền.
- F1-score class 1: 0.59 → Cân bằng giữa precision và recall, phản ánh mô hình cần cải thiện ở nhóm thiểu số.

Như vậy, mô hình đang hoạt động rất tốt với nhóm “không gửi tiền”, nhưng vẫn có thể cải thiện thêm ở nhóm “gửi tiền”, vốn là nhóm thiểu số (~12%).

a. Phân tích mô hình đã lựa chọn (XGBoost)

- Quan sát từ Confusion Matrix:

| | Dự đoán "no" | Dự đoán "yes" |
|---------------|--------------|---------------|
| Thực tế "no" | 11,260 | 684 |
| Thực tế "yes" | 699 | 921 |

- Đúng cả hai lớp: Mô hình phân loại đúng phần lớn khách hàng không gửi tiền (11,260) và đúng 921 khách hàng gửi tiền.
- Sai lệch: Có 684 khách hàng bị dự đoán nhầm là "yes" và 699 khách hàng thật sự gửi tiền nhưng bị dự đoán sai là "no".

b. Ý nghĩa và kết luận:

- Mô hình XGBoost cho kết quả rất tốt với tập dữ liệu mất cân bằng, đặc biệt hiệu quả ở nhóm đa số ("no").
- Đối với ngân hàng, việc phát hiện đúng khách hàng có khả năng gửi tiền (class "yes") là quan trọng hơn – nhằm tối ưu chiến dịch tiếp thị.
- Dù độ chính xác tổng thể cao, nhưng nhóm thiểu số (khách hàng "gửi tiền") vẫn còn bị bỏ sót tương đối.
- Gợi ý cải tiến:
 - o Điều chỉnh ngưỡng phân loại (threshold tuning)
 - o Ứng dụng kỹ thuật tăng cường dữ liệu như SMOTE để cân bằng lớp
 - o Kết hợp với chiến lược tiếp thị cá nhân hóa tập trung vào nhóm có xác suất cao

PHẦN 3: GIẢI PHÁP VÀ KIẾN NGHỊ

3.1. Ứng dụng của mô hình dự đoán

Qua phân tích và triển khai mô hình Machine Learning, nhóm đã xây dựng được một mô hình dự đoán khả năng **khách hàng đăng ký sử dụng dịch vụ tiền gửi tiết kiệm** dựa trên dữ liệu hành vi và đặc điểm nhân khẩu học từ chiến dịch marketing của ngân hàng.

Tối ưu hóa chiến dịch marketing qua điện thoại

- Mô hình giúp xác định trước nhóm khách hàng có khả năng cao đăng ký gửi tiền.
- Nhờ đó, ngân hàng sẽ tối ưu hóa nguồn lực gọi điện, tiết kiệm chi phí nhân sự và thời gian.

Tăng tỷ lệ chuyển đổi khách hàng

- Việc tập trung vào nhóm khách hàng tiềm năng giúp tăng tỷ lệ chuyển đổi từ liên hệ sang gửi tiền thực tế.
- Các chiến dịch marketing có thể được cá nhân hóa phù hợp với từng phân khúc.

Phân bổ nguồn lực hiệu quả

- Nhân viên telesale có thể ưu tiên gọi trước cho các nhóm khách hàng có điểm dự đoán cao.
- Quản lý có thể dễ dàng đánh giá hiệu quả chiến dịch theo từng nhóm mục tiêu.

Phân tích hành vi khách hàng sâu hơn

- Mô hình không chỉ hỗ trợ dự đoán mà còn giúp hiểu rõ đặc điểm hành vi của nhóm khách hàng gửi tiền (tuổi, nghề nghiệp, mức độ tương tác, lịch sử chiến dịch,...).
- Đây là cơ sở quan trọng cho việc thiết kế sản phẩm tiết kiệm phù hợp.

3.2. Các giải pháp và đề xuất về mặt nghiệp vụ

Từ các phân tích dữ liệu chi tiết trong phần II, ta có thể rút ra những đề xuất nghiệp vụ sau:

Tối ưu thời điểm liên hệ khách hàng

- Các tháng 5, 6, 7 là tháng có số lượng liên hệ nhiều nhưng tỷ lệ đăng ký thấp → cần giảm tần suất.
- Các tháng 3, 9, 12 có tỷ lệ thành công cao hơn → cần tăng cường liên hệ trong các tháng này.

Giới hạn số lần liên hệ để tránh gây phiền

- Khi khách hàng bị liên hệ quá nhiều lần (chỉ số campaign cao), tỷ lệ từ chối tăng → nên thiết lập ngưỡng giới hạn (ví dụ: không quá 3 lần/mỗi chiến dịch).
- Cần xây dựng hệ thống lưu lại lịch sử liên hệ để tránh trùng lặp hoặc gọi quá nhiều.

Ưu tiên nhóm khách hàng tiềm năng

- Phân tích cho thấy nhóm có khả năng gửi tiền cao gồm:
 - Người đã nghỉ hưu, nội trợ, sinh viên.
 - Khách hàng không vay mua nhà (housing = no).
 - Khách hàng có số dư tài khoản lớn hơn trung bình.

→ Ngân hàng nên tập trung tiếp cận các nhóm này để tăng hiệu quả chuyển đổi.

Kết hợp kết quả chiến dịch trước để ra quyết định

- Nếu khách hàng đã tham gia chiến dịch trước và thành công, họ có xu hướng tiếp tục gửi tiền (tỷ lệ đăng ký lại lên đến 64.3%).
- Ngược lại, nếu chiến dịch trước thất bại, khả năng từ chối rất cao (87.4%).

→ Do đó, cần ưu tiên nhóm đã từng thành công hoặc tìm cách thay đổi cách tiếp cận với nhóm từng thất bại.

Cải thiện chất lượng nhân viên telesale

- Cần tập huấn nhân viên:
 - Nhận diện khách hàng tiềm năng dựa trên dữ liệu.
 - Kỹ năng giao tiếp, chốt sale và xử lý từ chối.
 - Nắm bắt tâm lý từng phân khúc khách hàng theo độ tuổi, nghề nghiệp, trình độ học vấn.

3.3. Kiến nghị về mô hình dữ liệu và thu thập dữ liệu

Để nâng cao hiệu quả mô hình và đảm bảo tính chính xác, ổn định trong dự đoán hành vi khách hàng gửi tiền tiết kiệm, nhóm đề xuất một số kiến nghị cụ thể về dữ liệu như sau:

Mở rộng tập dữ liệu đầu vào

- Dữ liệu hiện tại chỉ bao gồm các đặc trưng nhân khẩu học và lịch sử liên hệ.
- Cần bổ sung thêm:
 - Lịch sử gửi tiền thực tế (nếu có).
 - Hành vi trên kênh online (ứng dụng, website).
 - Mức độ tương tác với các kênh truyền thông (email, quảng cáo).

Chuẩn hóa và làm sạch dữ liệu định kỳ

- Có nhiều trường bị sai lệch định dạng (ví dụ: nghề nghiệp bị viết sai, thiếu).
- Cần xây dựng quy trình:
 - Chuẩn hóa tên trường dữ liệu.
 - Loại bỏ trùng lặp.
 - Kiểm tra dữ liệu thiếu, sai logic (ví dụ: tuổi âm, thời lượng = 0...).

Bổ sung dữ liệu định tính

- Trong các chiến dịch gọi điện, nên ghi lại phản hồi của khách hàng: quan tâm, từ chối, lý do từ chối.
- Những thông tin định tính này có thể được mã hóa thành số để đưa vào mô hình học máy.

Thiết lập cơ chế cập nhật mô hình định kỳ

- Mô hình nên được huấn luyện lại theo chu kỳ (ví dụ: mỗi quý) để phản ánh đúng xu hướng khách hàng.
- Tạo hệ thống tự động thu thập dữ liệu mới và đánh giá lại mô hình theo thời gian.

Tích hợp mô hình vào hệ thống ngân hàng

- Kết quả từ mô hình (score) nên được gắn với hồ sơ khách hàng trong hệ thống CRM.
- Từ đó, nhân viên marketing có thể thấy được xác suất gửi tiền và lập danh sách gọi điện ưu tiên.

THAM KHẢO

<https://thuvienphapluat.vn/chinh-sach-phap-luat-moi/vn/ho-tro-phap-luat/tu-van-phap-luat/62002/tien-gui-tiet-kiem-la-gi-ai-duoc-gui-tien-tiet-kiem-tai-ngan-hang>

<https://tapchicongthuong.vn/cac-nhan-to-anh-huong-den-quyet-dinh-chon-ngan-hang-gui-tiet-kiem-cua-khach-hang-ca-nhan-thanh-pho-nha-trang-126110.htm>

<https://kqtkd.duytan.edu.vn/goc-hoc-tap/ly-thuyet-ve-quyet-dinh-lua-chon-gui-tiet-kiem-tai-ngan-hang-thuong-mai>